

UNIVERSIDAD NACIONAL AGRARIA DE LA MOLINA

Departamento Académico Estadística e Informática



Sistema de detección de posibles fraudes en ofertas laborales mediante Web Scraping

Profesor(a): Ana Vargas

Integrantes:

- Delgado Conzuero, Nathaly Sadith
- Ochante Cerazo, Helmer Patrik Mateo
- Quispe Lopez, Daiby Jaime
- Veliz Camayo, Victor Hugo

2026 - I

LA MOLINA

1. Introducción

Las plataformas de empleo en línea han facilitado la búsqueda de trabajo al permitir acceder rápidamente a miles de ofertas. Sin embargo, entre estas publicaciones también pueden encontrarse anuncios con información poco clara o potencialmente fraudulentos. Ante esta situación, surge la necesidad de contar con herramientas que ayuden a identificar posibles señales de riesgo.

Por ello, este proyecto propone un sistema que recopila ofertas laborales de distintas plataformas y las analiza para detectar características sospechosas, brindando al usuario una herramienta de apoyo para realizar una búsqueda de empleo más informada y segura.

1.1. Variables identificadas

Variable	Descripción
Título del puesto	Nombre de la oferta laboral publicada.
Empresa	Nombre de la empresa que ofrece el empleo.
Fuente	Plataforma de donde se obtuvo la oferta (Hiring Cafe o Dynamite Jobs).
Categoría	Área o tipo de empleo al que pertenece la oferta.
Ubicación	Lugar o modalidad de trabajo (remoto, híbrido o presencial).
Salario	Remuneración ofrecida en la publicación, si está disponible.

Requisitos	Habilidades, conocimientos o experiencia solicitada al postulante.
Responsabilidades	Funciones y actividades que deberá desempeñar el candidato.
URL	Enlace de la oferta original.
Puntaje de riesgo	Valor numérico asignado según las señales de alerta detectadas.
Nivel de riesgo	Clasificación final de la oferta (bajo, medio o alto).
Razones del riesgo	Motivos por los cuales la oferta fue considerada potencialmente sospechosa.

2. Planteamiento del problema

Los portales de empleo remoto facilitan el acceso a oportunidades laborales internacionales, pero ese mismo formato de publicación rápida y poca verificación se presta para que circulen ofertas fraudulentas. Hay anuncios que prometen ingresos garantizados, piden pagos por adelantado, solicitan datos personales bajo el pretexto de un "proceso de selección", o que ni siquiera corresponden a una empresa real. Revisar manualmente cada anuncio buscando estas señales una por una es lento e inconsistente, sobre todo para alguien que está buscando trabajo bajo presión.

El problema concreto que aborda el proyecto es cómo identificar automáticamente, entre las ofertas recolectadas, cuáles presentan características de fraude, sin depender de que el usuario revise cada anuncio manualmente.

Para resolverlo, el sistema recopila datos reales (no simulados) de dos fuentes con estructura distinta: Hiring Cafe, que muestra un panel dinámico con scroll infinito y paginación, y Dynamite Jobs, que organiza sus ofertas en categorías separadas por tipo de rol. Sobre el texto de cada oferta (título, descripción, requisitos, responsabilidades) se aplican reglas heurísticas con expresiones regulares, donde cada coincidencia con un

patrón sospechoso suma puntos a un puntaje de riesgo. También se penalizan señales estructurales, como no tener una empresa identificada o tener descripciones demasiado cortas. Al final, cada oferta queda clasificada en uno de tres niveles de riesgo, junto con las razones puntuales que se detectaron, de modo que el usuario puede entender por qué una oferta quedó marcada como sospechosa en lugar de recibir solo una etiqueta sin explicación.

3. Objetivos

Objetivo general:

Diseñar e implementar un sistema de web scraping que recopila ofertas de empleo remoto de dos fuentes (Hiring Cafe y Dynamite Jobs) y calcula automáticamente su nivel de riesgo de fraude mediante reglas de expresiones regulares, apoyando al usuario en la identificación de publicaciones laborales potencialmente engañosas.

Objetivos específicos:

- Extraer datos estructurados (título, empresa, ubicación, salario, requisitos, responsabilidades) de ambas fuentes usando Selenium, manejando el contenido que se carga dinámicamente con JavaScript.
- Definir patrones regex que detectan señales típicas de fraude laboral (dinero fácil, pago previo, contacto informal por WhatsApp o Telegram, correos no corporativos, lenguaje de urgencia, entre otras), cada uno con un peso de riesgo asignado.
- Calcular un puntaje de riesgo por oferta y clasificarlo en niveles (Bajo, Medio, Alto), guardando las razones específicas detectadas como evidencia.
- Mostrar los resultados en una interfaz web simple hecha con Flask donde se ven las ofertas junto a su nivel de riesgo.

4. Justificación del problema

El crecimiento de las plataformas de empleo en internet ha facilitado la búsqueda de trabajo, pero también ha incrementado la presencia de ofertas con información dudosa o potencialmente fraudulenta. Debido a la gran cantidad de publicaciones que aparecen diariamente, resulta difícil para los usuarios revisar cada oferta de manera manual e identificar cuáles podrían representar un riesgo.

Por esta razón, surge la necesidad de desarrollar una herramienta que permita recopilar y analizar información de diferentes plataformas de empleo, con el fin de detectar de manera temprana posibles señales de fraude y brindar apoyo a los usuarios durante su proceso de búsqueda laboral.

5. Desarrollo del sistema

5.1. Estrategia de web scraping

- Acceso a las páginas

Se utilizó Selenium para extraer información de las páginas Hiring Cafe y Dynamite Jobs, ya que parte de su contenido se carga dinámicamente con JavaScript. El sistema primero accede a las páginas de listado y luego ingresa a cada oferta para obtener información más detallada.

- Manejo de restricciones

Se verificó que ambas plataformas contaran con un archivo robots.txt accesible y se realizó un scraping no intrusivo, limitando la cantidad de ofertas extraídas y agregando pausas entre las solicitudes para evitar sobrecargar los servidores.

Debido a que Selenium utiliza un navegador real, las peticiones se realizan con un User-Agent válido. Asimismo, no fue necesario implementar rotación de User-Agent ni mecanismos de caché, ya que el volumen de información recopilada fue reducido

- Contenido dinámico

Para obtener un mayor número de ofertas, se implementó el manejo de contenido dinámico y paginación. En Hiring Cafe se recorrieron varias páginas de resultados y en Dynamite Jobs se navegaron las diferentes categorías y sus respectivas ofertas.

- Consideraciones éticas y legales

El proyecto no recopila datos personales sensibles ni intenta acceder a información privada. La finalidad es únicamente académica y busca apoyar la identificación de posibles ofertas sospechosas a partir de información pública.

5.2. Almacenamiento de datos

No hay bases de datos en el programa, en cambio se usan archivos JSON, para almacenar la información obtenida mediante el web scraping, el archivo se crea con el siguiente código:

```
{  
  
    "titulo": "...", "empresa": "...", "categoria": "...", "salario": "...", "descripcion": "...",  
  
    "url": "...", "fuente": "Dynamite Jobs", "riesgo": 35, "nivel_riesgo": "Medio",  
  
    "razones": "Empresa no identificada; Descripción muy corta"  
}
```

5.3. Solución a la problemática:

Nuestro sistema implementa un sistema de filtro para detectar posibles riesgos en las ofertas laborales recibidas, almacenarlas y dar a conocer no solo el nivel de riesgo, sino el porqué del mismo, dando hincapié en las señales de riesgo que presenta cada oferta laboral. Los filtros utilizados van desde lectura de frases sospechosas:

```
(r"\b(dinero rapido|ganancias garantizadas)\b", 35, "Promesa de dinero fácil")
```

```
(r"\b(pago para postular|deposito previo)\b", 45, "Solicitud de pago previo")
```

```
(r"\b(whatsapp|telegram)\b", 25, "Contacto poco formal")
```

```
(r"\b(gmail|hotmail|yahoo)\.com\b", 25, "Correo no corporativo")
```

Campos vacíos de información importantes:

```
if empleo.get("empresa") in ["", "No encontrada", None]:
```

```
    riesgo += 20 # Empresa no identificada
```

Y ofertas con poca información:


```
if len(descripcion) < 150:
```

```
    riesgo += 15
```

5.4. Integración:

Finalmente las ofertas se separan por categorías, que sirven a su vez de filtros de búsqueda para la página web, donde el cliente podrá ordenar y buscar ofertas con pautas más específicas.

5.5. Diagrama de flujo



6. Resultados

6.1. Validación y métricas

Para saber si el sistema realmente aporta al problema planteado, se analizaron los resultados obtenidos después de extraer y clasificar las ofertas laborales. Se consideraron indicadores sencillos, pero útiles, que permiten observar el comportamiento del sistema y verificar si las reglas de riesgo están identificando ofertas que merecen una revisión más detallada.

Las métricas utilizadas fueron las siguientes:

- Cantidad total de ofertas analizadas.
- Número de ofertas obtenidas de cada fuente de información.
- Distribución de las ofertas según el nivel de riesgo asignado (bajo, medio y alto).
- Cantidad de ofertas por categoría laboral.
- Frecuencia de las razones de riesgo detectadas.

Además, se revisaron manualmente algunas ofertas clasificadas por el sistema para comprobar si las alertas generadas tenían relación con el contenido real de la publicación. Esto permitió verificar si las reglas implementadas eran razonables y si los resultados obtenidos tenían sentido.

El objetivo del sistema no es afirmar que una oferta es una estafa, sino servir como una herramienta de apoyo que ayude a identificar publicaciones que presentan características sospechosas y que, por lo tanto, requieren una revisión más cuidadosa.

Según los resultados para un análisis con 29 ofertas de trabajo en ‘Dynamite Jobs’ y 15 ofertas de trabajo en ‘Hiring Cafe’; existen 41 ofertas de trabajo que no presentan presuntos riesgos y 3 ofertas de trabajo que presentan un leve riesgo.

Ofertas por fuente:		Ofertas por nivel de riesgo:	
fuelle		nivel_riesgo	
Dynamite Jobs	29	Bajo	41
Hiring Cafe	15	Medio	3

6.2. Limitaciones

El sistema presenta algunas limitaciones, como por ejemplo no todas las ofertas publican la información de la misma manera. Algunas muestran requisitos muy detallados, mientras que otras apenas proporcionan información sobre el puesto, lo que dificulta realizar un análisis uniforme.

Otra limitación importante es que el sistema se basa en palabras clave y expresiones regulares para detectar posibles riesgos. Por esta razón, pueden existir casos en los que una oferta legítima sea marcada como sospechosa o que una oferta fraudulenta no contenga las palabras esperadas y no sea detectada.

Finalmente, este trabajo fue desarrollado con un número limitado de ofertas laborales. Para utilizarlo en un entorno real sería necesario implementar mecanismos de actualización automática, mejorar la escalabilidad y complementar las reglas actuales con técnicas más avanzadas.

7. Reflexión crítica sobre el uso de LLMs

Se utilizaron herramientas de inteligencia artificial como apoyo para generar una primera versión de algunas funciones, como la configuración de Selenium, el manejo de la paginación, las expresiones regulares del detector de fraude y algunas operaciones con pandas.

Sin embargo, fue necesario realizar modificaciones manuales, como ajustar los selectores HTML, configurar los tiempos de espera (`time.sleep()`), manejar el contenido dinámico de las páginas e incorporar nuevas reglas y palabras clave para mejorar la detección de riesgos.

En general, estas herramientas ayudaron a acelerar el desarrollo inicial del proyecto, pero la integración de las dos fuentes de información, la validación de los datos extraídos y el funcionamiento final del sistema fueron realizados por el equipo.

8. Conclusiones

- La integración de web scraping, procesamiento de datos y visualización de información demostró que es posible construir una herramienta práctica para apoyar la detección temprana de posibles fraudes laborales, reduciendo el tiempo de búsqueda y facilitando el análisis de un gran número de ofertas de empleo.

- El sistema desarrollado permite identificar de manera automática ofertas laborales con características potencialmente sospechosas mediante el uso de palabras clave y expresiones regulares, ayudando a los usuarios a reconocer publicaciones que requieren una revisión más detallada.